Relatório - Projeto Final de PLN

Adriel F. Trajano, Erlon Lacerda Avelino, Kamily A. de Oliveira, Paloma Duarte de Lira

[1]Centro de Informática – Universidade Federal da Paraíba (UFPB)
João Pessoa, PB, Brasil

{adriel.ferreira, erlon.avelino}@academico.ufpb.br

{kamilyfacul, duartepaloma0701}@gmail.com

Resumo. *Este relatório técnico descreve o desenvolvimento de um sistema de classificação de técnicas de persuasão política com base em notícias e artigos de opinião de língua portuguesa. O projeto utiliza modelos de linguagem de baixo custo baseados em Transformers, especialmente BERT, treinados sobre um corpus construído a partir de múltiplas fontes: o dataset FakeTrueBr, notícias coletadas via scraping da seção Fato ou Fake do portal de notícias G1, dados do portal Conexão Política e o dataset SemEval Task 3 (2023), utilizado como referência para o processo de rotulação. O pipeline contempla etapas de coleta, pré-processamento (sentenciamento e normalização textual) e rotulação não-supervisionada através de LLMs, seguidas do fine-tuning dos modelos para a tarefa de classificação.*

Palavras-chave*: Processamento de Linguagem Natural, Técnicas de Persuasão, BERT, Rotulação com LLMs.*

1. Apresentação do Problema

A proliferação de notícias falsas e conteúdo de desinformação representa um dos principais desafios contemporâneos para a comunicação pública e a democracia. No contexto político brasileiro, esse fenômeno é especialmente crítico: notícias são enviesadas utilizando técnicas retóricas e persuasivas sofisticadas para influenciar a opinião pública e distorcer fatos.

Identificar *quais* técnicas de persuasão estão sendo empregadas em um texto, para além de apenas classificá-las como verdadeiro ou falso, é uma tarefa de grande relevância analítica. Trata-se de um problema de classificação multiclasse em linguagem natural, no qual um modelo deve, dado um trecho textual, reconhecer padrões de duplicidade humana como apelo emocional, descredibilidade e minimização.

2. Objetivos

O objetivo deste projeto foi desenvolver um classificador capaz de identificar as 7 técnicas de persuasão mais comuns identificadas pelos estudos do SemEval como presentes na linguagem usada para discorrer temas politícos. Para isso, o projeto abrange:

- Coleta e consolidação de um dataset em português brasileiro a partir de fontes diversificadas;

- Rotulação semi-automática dos dados utilizando o esquema de anotação do SemEval Task 3 (2023) como referência;
- Treinamento e avaliação de modelos Transformer (BERT: tiny, mini e small) para a tarefa de classificação de novos dados.

2.1. Relevância da Solução

A solução contribui para o desenvolvimento de ferramentas de combate à desinformação, adaptadas ao contexto linguístico e político brasileiro, relevantes para a área de PLN, já que é um dos idiomas com menor disponibilidade de recursos anotados.

O sistema também oferece uma camada de análise profunda, capaz de subsidiar pesquisadores, jornalistas e plataformas de checagem de fatos com informações mais detalhadas sobre os mecanismos retóricos comumente empregados na desinformação.

2.2. Inovação

A solução proposta consiste em um classificador de notícias em português, treinado a partir da integração de múltiplas fontes de dados com os datasets FakeTrueBR, G1 e Conexão Política. Essa combinação permitiu maior diversidade textual e melhor representação do contexto.

A principal inovação deste trabalho reside na adaptação: enquanto os datasets existentes com esse tipo de taxonomia estão majoritariamente disponíveis em inglês, ainda há escassez de recursos equivalentes em português. Assim, propomos a construção de um processo de rotulação estruturado nesse idioma, contribuindo para a expansão de recursos em PLN voltados à detecção de técnicas de desinformação e análise de discurso político.

2.3. Dados e Pré-processamento

O corpus do projeto foi construído a partir das seguintes fontes:

- **FakeTrueBr**: dataset público contendo notícias em português já rotuladas como verdadeiras ou falsas, utilizado como base inicial do corpus;
- **G1 — Fato ou Fake**: notícias coletadas via *web scraping* da seção de checagem de fatos do portal G1, aproveitando a estrutura editorial existente para identificação de conteúdo verificado;
- **Conexão Política**: portal de notícias políticas brasileiras, cujos textos foram incorporados ao corpus após processo de sentenciamento;
- **SemEval Task 3 (2023)**: dataset multilíngue de referência para identificação de técnicas de persuasão, utilizado como guia para o processo de rotulação automática dos demais dados.

O pré-processamento adotou as seguintes etapas:

- **Scraping**: para os dados provenientes do G1, foi desenvolvido um pipeline de coleta automatizada utilizando técnicas de *web scraping*, responsável pela extração e estruturação das notícias diretamente das páginas do portal;
- **Sentenciamento**: para os datasets FakeTrueBr e Conexão Política, os textos foram segmentados em sentenças individuais, granularidade necessária para o alinhamento com o esquema de rotulação do SemEval;

- **Rotulação com LLM**: os textos foram anotados automaticamente com o modelo GPT-4.1-nano, utilizando as categorias de técnicas de persuasão definidas pelo SemEval Task 3 como esquema de classificação, gerando assim os rótulos-alvo para o treinamento. Prompt utilizado:

  "Your Role: Professional Data Annotator specializing in identifying persuasion techniques in news sentences.
  Short basic instruction: Assign one persuasion technique label (or No_Label) to a sentence and justify it briefly.
  What you should do:
  Carefully read the provided sentence and evaluate it against all available persuasion technique labels.
  *Compare at least two plausible labels before selecting the **single best-fitting label**.*
  *If none of the defined techniques apply, assign **No_Label**.*
  Then provide a short justification based strictly on the wording of the sentence.
  Your Goal:
  Produce consistent, accurate annotations by selecting the most appropriate persuasion technique (or correctly identifying absence of one) and briefly explaining the decision using textual evidence.
  Result:
  Return a structured output containing:
  - `label`*: the selected category (exactly one)*
  - `justification`*: a concise explanation referencing specific words, tone, or phrasing*

  Available labels and definitions:
  1. ***Loaded language**: Words or phrases with strong emotional implications used to influence perception.*
  2. ***Name calling or labeling**: Assigning a label to evoke fear, hatred, admiration, or approval.*
  3. ***Doubt**: Questioning the credibility or reliability of a person, group, or idea.*
  4. ***Repetition**: Reusing the same phrase or idea multiple times to reinforce a message.*
  5. ***Appeal to fear/prejudice**: Creating anxiety, panic, or bias toward an alternative or group.*
  6. ***Flag-waving**: Appealing to national, group, or identity-based pride to justify an idea.*
  7. ***Exaggeration or minimization**: Overstating or understating facts to distort perception.*
  8. ***No_Label**: The sentence does not clearly exhibit any of the above techniques.*

  Few-shot examples:
  Example 1:
  Sentence: "Outrage as Donald Trump suggests injecting disinfectant to kill virus."
  Output:

- *label: Loaded language*
- *justification: The word "Outrage" carries strong emotional weight to influence perception.*

Example 2:
Sentence: "WHO: Coronavirus emergency is 'Public Enemy Number 1' "
Output:

- *label: Name calling or labeling*
- *justification: The phrase "Public Enemy Number 1" assigns a strong negative label.*

Example 3:
Sentence: "Can the same be said for the Obama Administration?"
Output:

- *label: Doubt*
- *justification: The question challenges the credibility of the Obama Administration.*

Example 4:
Sentence: "I have a dream... I have a dream... "
Output:

- *label: Repetition*
- *justification: The phrase "I have a dream" is repeated to reinforce the message.*

Example 5:
Sentence: "A dark, impenetrable and irreversible winter will fall upon us."
Output:

- *label: Appeal to fear/prejudice*
- *justification: The sentence creates fear using alarming imagery like "dark" and "irreversible winter."*

Example 6:
Sentence: "We must defend our nation and protect our people at all costs."
Output:

- *label: Flag-waving*
- *justification: Appeals to national identity with phrases like "our nation" and "our people."*

Example 7:
Sentence: "The risk to the public remains very low."
Output:

- *label: Exaggeration or minimization*
- *justification: The phrase "very low" downplays the perceived risk.*

Example 8:
Sentence: "The meeting will take place at 3 PM tomorrow."
Output:

- *label: No_Label*

- *justification: The sentence is purely informational and contains no persuasive or emotional elements.*

Constraint:

- *Use only the provided sentence; do not rely on external knowledge or assumptions.*
- *Do not hallucinate missing context.*
- *Assign exactly one label per sentence.*
- *Use No_Label only when none of the defined techniques clearly apply.*
- *Keep explanations short, precise, and grounded in explicit wording.*
- *Always include a comparison with at least one alternative label (or explain absence for No_Label).*
- *The input may be in English or Brazilian Portuguese — interpret accordingly.*

Context: You will receive isolated sentences that may not represent a full article. Each sentence must be evaluated independently."

2.4. Técnicas Utilizadas

A abordagem técnica do projeto é baseada em modelos de linguagem pré-treinados do tipo Transformer, com *fine-tuning* supervisionado para a tarefa de classificação de técnicas de persuasão.

2.4.1. Implementação

Dois modelos foram selecionados para experimentação:

- **BERT** (*Bidirectional Encoder Representations from Transformers*): modelo bidirecional pré-treinado amplamente utilizado em tarefas de classificação de texto. Foi realizado *fine-tuning* sobre o corpus rotulado construído na etapa anterior, adaptando o modelo à tarefa específica de identificação de técnicas de persuasão em português;

O treinamento foi conduzido utilizando os dados coletados e rotulados conforme descrito na seção anterior, com divisão em conjuntos de treino, validação e teste.

2.4.2. Vantagens

A escolha de modelos baseados em Transformers traz vantagens significativas para esta tarefa:

- **Representação contextual**: ao contrário de abordagens baseadas em *bag-of-words* ou embeddings estáticos, BERT captura o significado das palavras em função de seu contexto, essencial para identificar nuances retóricas e persuasivas no texto;
- **Transferência de conhecimento**: o pré-treinamento em grandes corpora permite que os modelos partam de representações linguísticas ricas, reduzindo a necessidade de grandes volumes de dados rotulados para a tarefa específica;
- **Estado da arte em PLN**: ambos os modelos representam abordagens consolidadas com desempenho de ponta em benchmarks de classificação de texto, conferindo robustez metodológica ao projeto.

3. Apresentação da Solução

A solução desenvolvida consiste em um pipeline completo de PLN, estruturado em três grandes módulos:

(1) Coleta e construção do corpus: integração das fontes FakeTrueBr, G1 (*scraping*), Conexão Política e SemEval Task 3 em um corpus unificado. O *scraping* do G1 foi desenvolvido de forma customizada para a estrutura do portal, e os textos coletados foram padronizados em formato compatível com os demais datasets.

(2) Pré-processamento e rotulação: os textos foram segmentados em sentenças para permitir uma análise mais detalhada das estratégias discursivas. Em seguida, realizou-se a rotulação automática com base no esquema de técnicas de persuasão do *SemEval Task 3*, adaptado para o português. Cada sentença foi classificada nas categorias *Neutro*, *Descredibilização*, *Imposição*, *Apelo ao Medo*, *Repetição*, *Exagero ou Minimização*, *Apelo Patriótico* e *Palavras Fortes*, que representam diferentes estratégias retóricas de influência.

(3) Treinamento e classificação: os modelo foi submetido a *fine-tuning* sobre o corpus rotulado, produzindo classificadores capazes de identificar automaticamente as técnicas de persuasão presentes em novos textos em português.

Todo o desenvolvimento foi conduzido em notebooks Jupyter, com o código e os experimentos versionados e disponibilizados no repositório público do projeto no GitHub[1].

3.1. Experimento

A solução foi desenvolvida utilizando modelos baseados na arquitetura BERT, especificamente as variantes *BERT-tiny*, que são versões mais leves e eficientes do modelo original, adequadas para cenários com restrições computacionais e necessidade de rápida inferência.

O problema foi tratado como uma tarefa de classificação multiclasse, considerando um total de 8 classes distintas. Para o pré-processamento dos dados, os textos foram tokenizados e truncados para um comprimento máximo de 512 tokens, garantindo padronização nas entradas do modelo.

O treinamento foi realizado com tamanho de lote (*batch size*) igual a 32, ao longo de 20 épocas. Foi utilizada uma taxa de aprendizado inicial de 5×10^{-5}, com aplicação de *warm-up* correspondente a 10% do total de passos de treinamento, estratégia que auxilia na estabilização do processo de otimização nas etapas iniciais. Além disso, foi aplicado *weight decay* de 0.01 como forma de regularização, contribuindo para a redução de *overfitting*.

4. Resultados

O modelo *BERT-tiny* apresentou desempenho consistente ao longo do treinamento, convergindo de forma estável. Na época 19 de um total de 20, obteve-se uma loss de treinamento de 0.3210 e uma loss de validação de 0.4042, indicando boa capacidade de generalização. Além disso, o modelo alcançou uma acurácia de validação de 86%, evidenciando sua eficácia na tarefa de classificação das técnicas de persuasão em notícias em português.

Abaixo, temos as métricas do treinamento:

[1] `https://github.com/kamilyassis/pln`

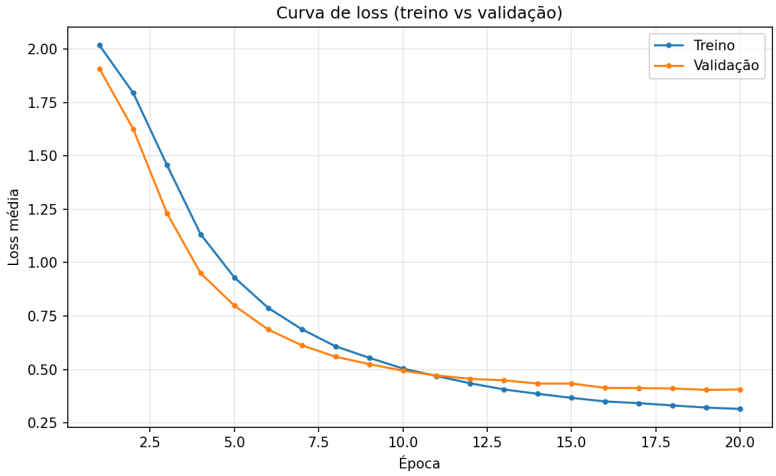

Figure 1. Curva de loss

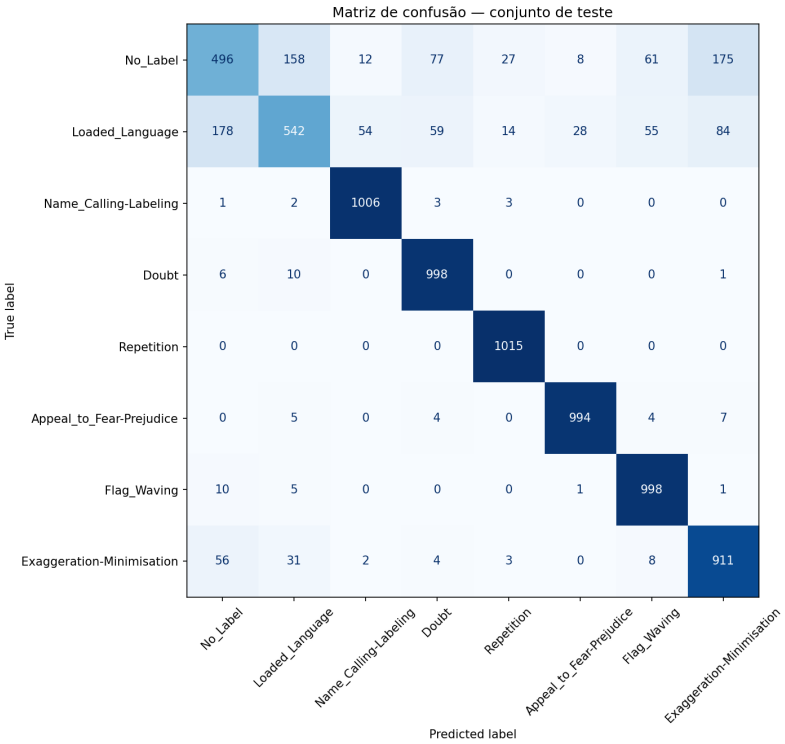

Figure 2. Matriz de Confusão

```
Epoch 19/20 | Train Loss: 0.3210 | Val Loss: 0.4042 | Val Acc: 0.8608
              precision    recall  f1-score   support

           0       0.65      0.51      0.57      1015
           1       0.70      0.53      0.60      1015
           2       0.95      1.00      0.97      1015
           3       0.90      0.98      0.94      1014
           4       0.96      1.00      0.98      1014
           5       0.97      0.98      0.97      1015
           6       0.89      0.98      0.93      1015
           7       0.78      0.90      0.84      1014

    accuracy                           0.86      8117
   macro avg       0.85      0.86      0.85      8117
weighted avg       0.85      0.86      0.85      8117
```

Figure 3. Relatório de classificação

5. Análise Crítica, Limitações e Lições

O desenvolvimento do projeto trouxe aprendizados importantes tanto do ponto de vista técnico quanto organizacional. A seguir, são discutidas as principais limitações encontradas e as lições aprendidas ao longo do processo.

5.1. Limitações

- **Tempo**: o prazo disponível para o desenvolvimento do projeto impôs restrições ao escopo dos experimentos, inviabilizando, por exemplo, uma busca mais exaustiva de hiperparâmetros e a experimentação com versões multilíngues dos modelos especializadas em português, como BERTimbau;
- **Elaboração da Ideia**: a definição da abordagem de rotulação automática baseada no SemEval demandou tempo considerável de discussão e validação, uma vez que a transposição do esquema de anotação multilíngue para o contexto brasileiro não é direta e exigiu adaptações;
- **Definição de Escopo**: a diversidade das fontes de dados e a multiplicidade de técnicas de persuasão catalogadas pelo SemEval tornaram necessária uma delimitação cuidadosa do escopo do classificador, priorizando as categorias com maior representatividade no corpus coletado;
- **Protótipo**: por se tratar de um projeto acadêmico com restrições de tempo e infraestrutura, o sistema desenvolvido tem caráter de protótipo, não tendo sido submetido a testes de desempenho em produção ou integrado a interfaces de uso final.

5.2. Lições Aprendidas

Apesar das limitações apresentadas, o projeto proporcionou aprendizados relevantes para todos os integrantes da equipe:

- **Trabalho em equipe**: a divisão das tarefas entre coleta de dados, pré-processamento e modelagem exigiu comunicação constante e alinhamento entre os membros do grupo, reforçando a importância de práticas de desenvolvimento colaborativo como o uso de controle de versão (Git/GitHub) e documentação progressiva dos experimentos em notebooks;

- **Otimização**: o processo de *fine-tuning* de modelos Transformer revelou a sensibilidade desses modelos a escolhas de hiperparâmetros como taxa de aprendizado, tamanho de *batch* e número de épocas, evidenciando a necessidade de estratégias sistemáticas de otimização mesmo em contextos com recursos computacionais limitados.

6. Referências

- MONTEIRO, R. A. et al. **FakeTrueBr Corpus**: a Benchmark for Fake News Detection in Brazilian Portuguese. In: *Proceedings of the 8th Brazilian Conference on Intelligent Systems (BRACIS)*, 2019.
- DA SILVA, N. F. F. et al. Towards Automatic Fake News Detection in Brazilian Portuguese. *arXiv preprint*, 2020.
- PISKORSKI, J. et al. **SemEval-2023 Task 3**: Detecting the Category, the Framing, and the Persuasion Techniques in Online News in a Multi-lingual Setup. In: *Proceedings of the 17th International Workshop on Semantic Evaluation (SemEval-2023)*, 2023.
- DEVLIN, J. et al. **BERT**: Pre-training of Deep Bidirectional Transformers for Language Understanding. In: *Proceedings of NAACL-HLT 2019*, 2019.
- YANG, Z. et al. **XLNet**: Generalized Autoregressive Pretraining for Language Understanding. In: *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.